Détection d'anomalies dans les données de fret

Architecture, raisonnement et manuel d'utilisation

Plateforme serverless sur AWS — ingestion UN Comtrade, calcul des écarts mirror-matching, tableau de bord et rapports d'anomalie rédigés par un modèle de langage.

HES-SO · CloudSys, projet 3 · groupe 16

Iseni Aladin · Steiner Jeremiah · Nunez Tania

Dépôt : `cldsys-trade_anomaly`

Table des matières

1. Vue d'ensemble
2. Schéma d'architecture
3. Raisonnement architectural
4. Modèle de données
5. Authentification et sécurité
6. Workflow détaillé : clic sur une cellule rouge
7. Manuel d'utilisation
8. Limites et pistes d'évolution

1. Vue d'ensemble

La plateforme détecte les anomalies dans les statistiques de commerce international publiées par UN Comtrade, par **mirror-matching** : la valeur à l'exportation déclarée par le pays A vers le pays B (FOB) est comparée à la valeur à l'importation déclarée par B depuis A (CIF), en prix unitaire USD par tonne. Une cellule est signalée comme anomalie si le prix FOB dépasse le prix CIF, si l'écart (CIF − FOB) / FOB dépasse 35 %, ou si le flux n'est déclaré que par un seul des deux pays.

Trois usages traversent la plateforme, chacun porté par un flux serverless indépendant :

- **Ingestion et calcul** — chaque semaine, l'historique complet (2019 à aujourd'hui) est rechargé depuis l'API UN Comtrade et les écarts sont recalculés pour l'ensemble des exportateurs, produits et fréquences suivis.
- **Consultation** — un tableau de bord web affiche une heatmap des dix principaux partenaires d'un exportateur et d'un produit donnés, période par période.
- **Rapport par IA** — un clic sur une cellule rouge (anomalie) démarre, de façon asynchrone, la rédaction d'un rapport PDF expliquant l'écart à partir des données commerciales et, si disponible, de contexte externe.

L'ensemble repose sur des services AWS entièrement managés : aucun serveur, conteneur ou cluster n'est maintenu en permanence, et la facturation suit l'usage réel de la plateforme.

2. Schéma d'architecture

Le schéma ci-dessous se lit en trois colonnes, chacune correspondant à un des trois flux décrits en section 1. Les flèches pleines représentent un appel ou une écriture, les flèches pointillées une lecture.

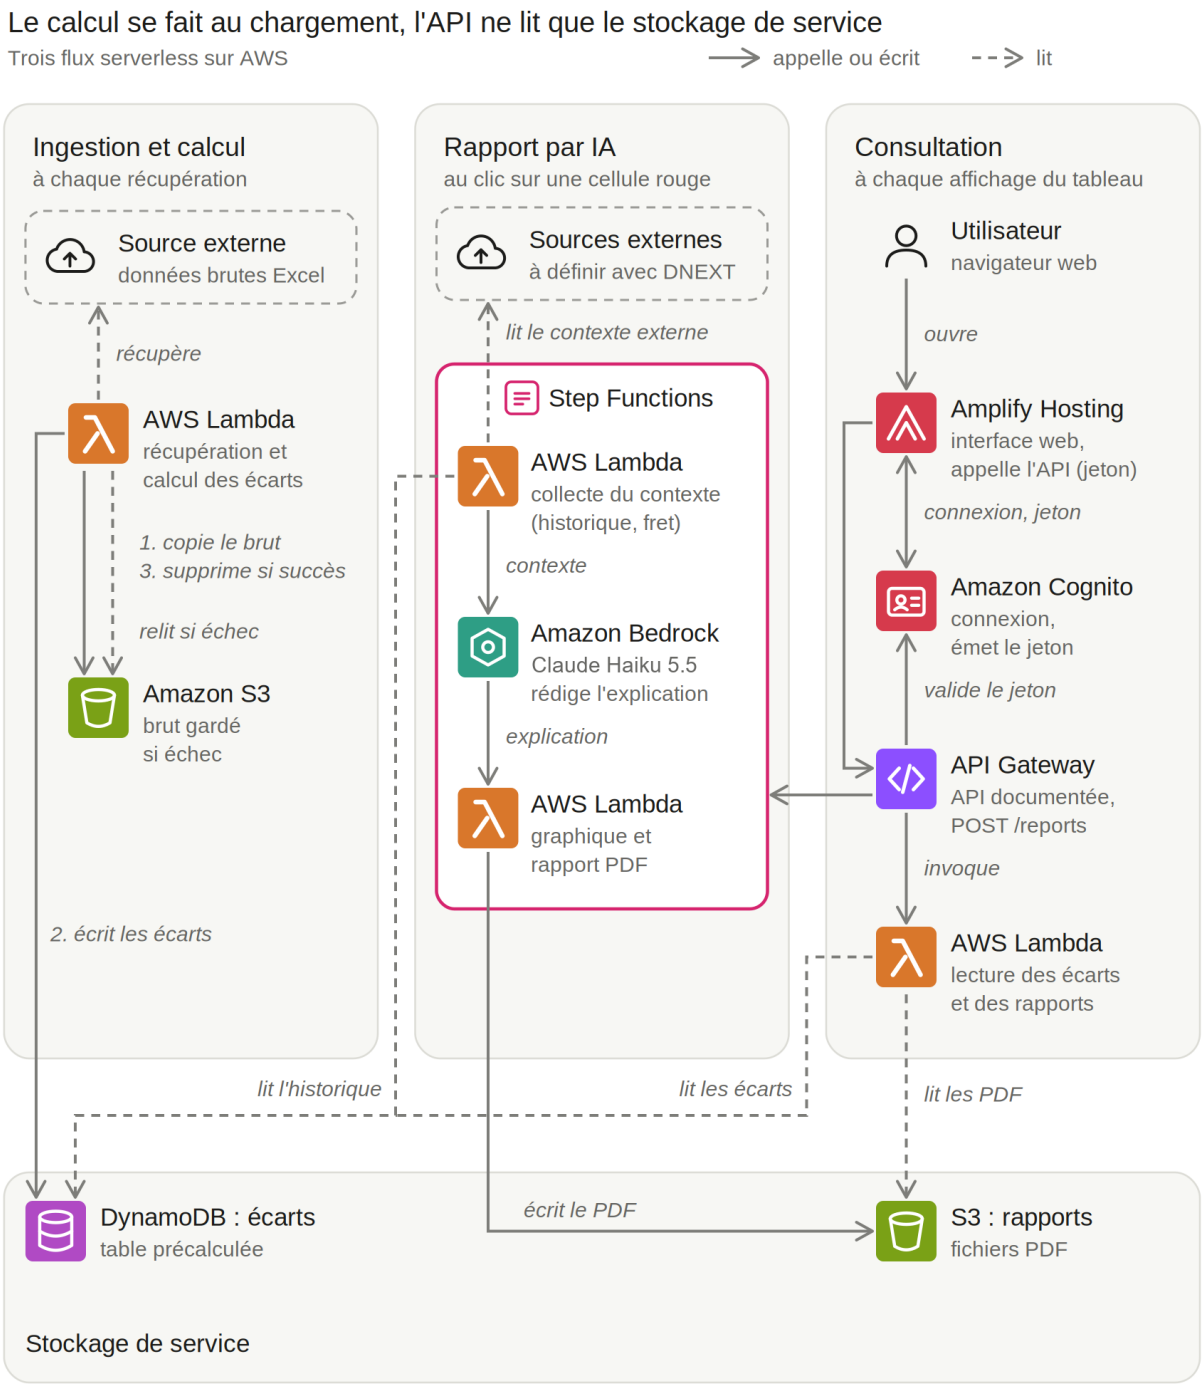


Figure 1 — Les trois flux serverless de la plateforme.

Trois précisions de lecture. Premièrement, Amazon Cognito n'est pas sur le chemin de chaque requête : l'utilisateur s'y authentifie une fois, puis API Gateway vérifie lui-même le jeton joint à chaque appel (voir section 5). Deuxièmement, les deux espaces S3 du schéma sont deux buckets distincts et privés : l'un pour la réponse brute de l'API Comtrade (gardée pour reprise en cas d'échec), l'autre pour les rapports PDF. Troisièmement, l'étape « Rapport par IA » est asynchrone de bout en bout : l'API répond dès le démarrage du workflow, et l'interface suit l'avancement par sondage (voir section 6).

3. Raisonnement architectural

3.1 Parti pris : une architecture entièrement serverless

La charge de la plateforme est faible et irrégulière : les données ne changent qu'une fois par semaine, le tableau de bord est consulté ponctuellement, et un rapport n'est généré qu'au clic sur une cellule. Des ressources allumées en permanence — qu'il s'agisse de conteneurs ou d'un cluster provisionné — resteraient donc inactives la plupart du temps. Nous retenons par conséquent des services managés, facturés à l'usage, sans serveur à administrer.

Cette position comporte des limites que nous assumons : une fonction Lambda est bornée à 15 minutes d'exécution, ce qui borne en retour la taille d'un rechargement complet (voir section 8). Le calcul du mirror-matching lui-même — une jointure entre la déclaration de l'exportateur et celle de l'importateur, suivie d'une expression arithmétique — ne justifie pas un entrepôt de données séparé : nous l'exécutons directement en Python dans la fonction d'ingestion, au moment du chargement hebdomadaire, et le tableau de bord ne lit jamais autre chose que le résultat déjà calculé dans DynamoDB. Une architecture appuyée sur un entrepôt managé (Redshift Serverless) avait été envisagée à la conception, pour s'aligner sur des volumes de données plus importants ; le périmètre réel du projet — quelques dizaines de milliers de cellules, un chargement hebdomadaire — ne la justifiait pas, et nous l'avons écartée au profit d'un calcul direct, plus simple à exploiter et moins coûteux à l'arrêt.

3.2 Justification des choix de service

Pour chaque service retenu, le tableau indique son rôle précis dans la plateforme ainsi que l'alternative écartée et la raison de ce choix.

Service	Rôle et justification	Alternative écartée
AWS Lambda	Exécute tous les traitements courts et sans état : ingestion, API, collecte du contexte et appel au modèle, construction du PDF.	Conteneurs (ECS Fargate), qui tourneraient en continu pour un trafic ponctuel ; AWS Glue, conçu pour des volumes bien supérieurs aux nôtres.
Amazon DynamoDB	Sert les écarts précalculés au tableau de bord en quelques millisecondes, en mode PAY_PER_REQUEST adapté à une charge irrégulière ; une seule requête par exportateur et produit suffit à afficher la heatmap.	Lecture directe de la source externe à chaque affichage : latence et complexité inutiles pour une donnée qui ne change qu'une fois par semaine.
Amazon S3 (2 buckets)	Stocke la réponse brute de l'API Comtrade (reprise sans nouvel appel externe en cas d'échec) et les rapports PDF, dans deux buckets privés distincts.	Bucket public pour les rapports : lisible sans authentification, incompatible avec le contrôle d'accès par Cognito.
AWS Step Functions (Standard)	Orchestre le workflow de rapport en deux étapes (Explain, BuildPdf), avec reprise (Retry) par étape, historique d'exécution consultable, et un nom d'exécution déterministe qui rend la demande de rapport idempotente.	Une seule fonction Lambda enchaînant tout : aucune reprise par étape, et un risque réel de dépasser la limite de 15 minutes.
Amazon EventBridge Scheduler	Déclenche le rechargement hebdomadaire sans tâche planifiée externe à maintenir.	Cron hors AWS (CI externe) : dépendance supplémentaire pour une tâche interne à l'infrastructure.
Amazon API Gateway (HTTP API)	Expose l'API documentée (OpenAPI) ; autorisateur JWT Cognito natif, qui vérifie le jeton avant toute invocation Lambda ; CORS limité aux origines autorisées.	REST API : plus riche (WAF, plans d'usage) mais plus lourde et plus chère ; reste le repli si un pare-feu applicatif devenait nécessaire.

Service	Rôle et justification	Alternative écartée
Amazon Cognito	Authentifie les utilisateurs (comptes créés par un administrateur) et émet les jetons que l'API vérifie. Une requête non authentifiée ne déclenche ni Lambda, ni Step Functions, ni Bedrock.	Clé API statique dans le front-end, lisible par tout visiteur ; authentification développée sur mesure, à maintenir sans bénéfice.
Amazon Bedrock (Claude Haiku 5.5)	Rédige l'explication structurée de l'anomalie. L'accès se fait par le rôle IAM de la fonction, sans clé à gérer ; le modèle reste configurable par paramètre.	API hors AWS, avec clé externe et facturation séparée du reste de l'infrastructure.
AWS Amplify Hosting	Héberge le tableau de bord, construit et déployé automatiquement depuis le dépôt GitHub à chaque `git push`.	S3 + CloudFront : résultat équivalent, mais chaîne de déploiement à construire et à maintenir soi-même.
AWS SAM	Décrit toute l'infrastructure backend dans le dépôt (infrastructure as code), pour un déploiement reproductible par toute l'équipe.	Configuration manuelle dans la console AWS : non reproductible, non versionnée.

4. Modèle de données

La plateforme repose sur une unique table DynamoDB (`gaps`), en mode à la demande. Afficher la matrice d'un exportateur et d'un produit doit coûter une seule requête : la clé de partition combine l'exportateur, le produit et la fréquence, la clé de tri combine la période et le partenaire.

- **Écarts** — `pk = exportateur#produit#fréquence`, `sk = période#partenaire`. Chaque élément porte le prix FOB, le prix CIF, l'écart, le statut (cohérent / anomalie / anomalie à sens unique) et le nombre de mois déclarés de chaque côté.
- **Poids des partenaires** — `pk = exportateur#produit#WEIGHTS`, un élément par année, utilisé pour sélectionner les dix partenaires affichés sur la heatmap (le plus grand des deux montants déclarés, pour que les flux à sens unique pèsent aussi).

Aucune table séparée ne suit le statut des rapports : le nom de l'exécution Step Functions est l'identifiant du rapport (`{exportateur}-{partenaire}-{produit}-{fréquence}-{période}`), si bien que la présence du PDF dans S3 signifie « généré », et le statut de l'exécution du même nom donne « en cours » ou « échec » sinon.

5. Authentification et sécurité

L'authentification se prête bien à une architecture serverless, car elle y est sans état : aucune session n'est conservée côté serveur, l'identité de l'utilisateur voyage dans un jeton signé (JWT) que chaque appel présente. Amazon Cognito émet les jetons ; API Gateway les vérifie avant d'invoquer la moindre fonction.

- **Comptes** — créés uniquement par un administrateur (`admin-create-user`) ; l'auto-inscription est désactivée.
- **Jetons** — vérifiés par l'autorisateur JWT natif d'API Gateway, sans Lambda intermédiaire ; une requête sans jeton valide n'atteint jamais le code applicatif.
- **Secrets** — la clé de l'API UN Comtrade est stockée chiffrée dans Parameter Store (`SecureString`) et lue à l'exécution par la seule fonction d'ingestion ; aucun secret n'apparaît dans le dépôt ou dans CloudFormation.
- **Accès au modèle** — Bedrock est invoqué par le rôle IAM de la fonction (SigV4), sans clé API Anthropic à distribuer ou à faire tourner.
- **Téléchargement des rapports** — le bucket des PDF reste privé ; l'API, après vérification du jeton, renvoie une URL pré-signée valable 15 minutes.
- **Permissions** — chaque fonction a son propre rôle IAM, limité aux ressources qu'elle utilise réellement (voir *architecture-technique.md*, section 5, pour le détail).

6. Workflow détaillé : clic sur une cellule rouge

Une cellule rouge de la heatmap signale une anomalie. Le clic démarre un parcours en deux temps : une partie **synchrone**, qui valide la demande et démarre le traitement, et une partie **asynchrone**, orchestrée par Step Functions, dont l'interface suit l'avancement par sondage.

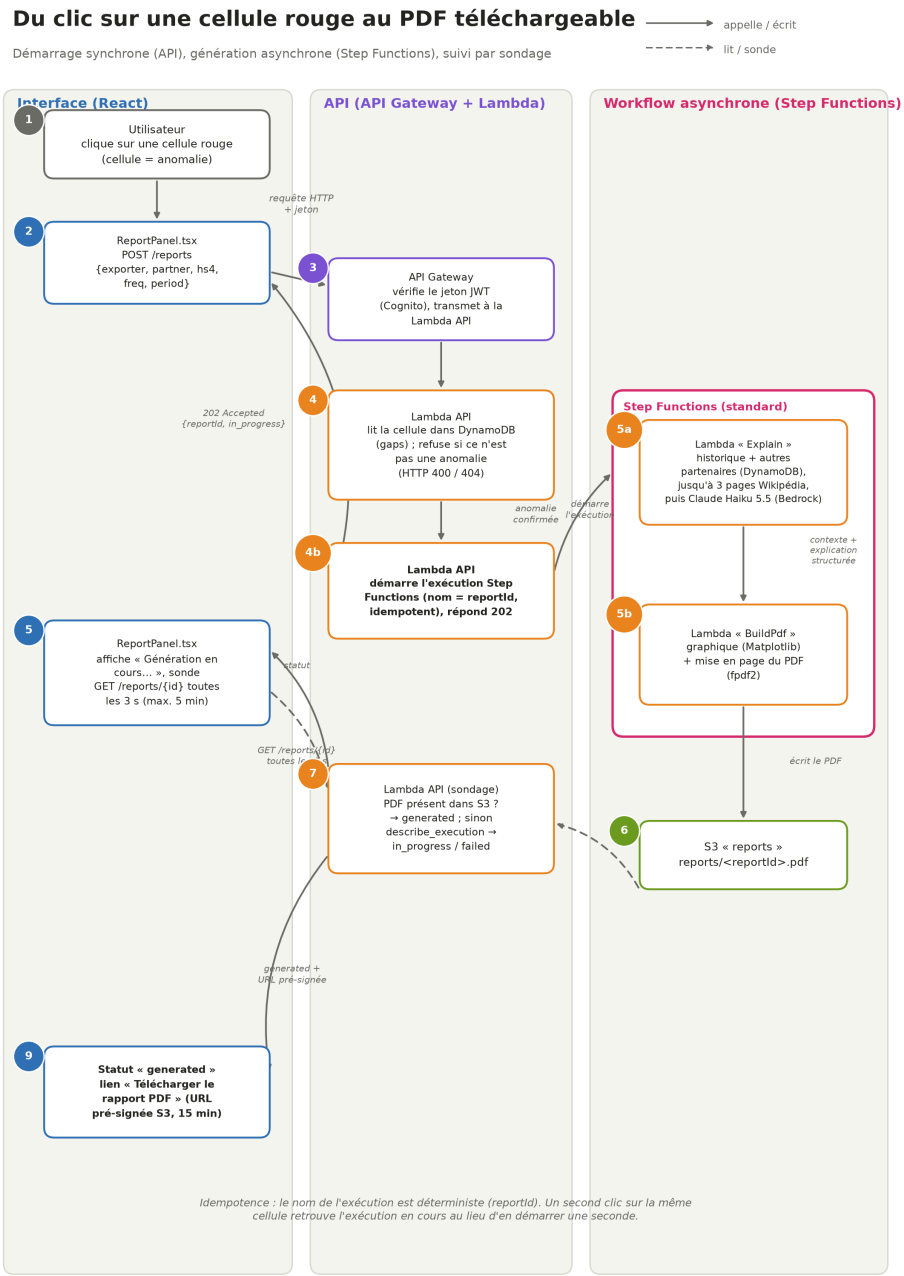


Figure 2 — Séquence complète, du clic à l'URL de téléchargement.

6.1 Démarrage (synchrone)

- L'utilisateur clique sur une cellule marquée comme anomalie ; seules ces cellules sont cliquables dans l'interface.
- Le composant `ReportPanel` envoie `POST /reports` avec l'exportateur, le partenaire, le produit, la fréquence et la période de la cellule.
- API Gateway vérifie le jeton JWT avant de transmettre la requête à la fonction API.

- La fonction API relit la cellule dans DynamoDB et refuse (400/404) si elle n'est pas une anomalie — une protection contre un appel direct à l'API qui contournerait l'interface.
- Elle démarre l'exécution Step Functions en lui donnant pour nom l'identifiant du rapport. Comme ce nom est déterministe, un second clic sur la même cellule retrouve l'exécution déjà en cours plutôt que d'en démarrer une seconde : la demande de rapport est **idempotente**.
- L'API répond aussitôt `202 Accepted` avec le statut `in_progress` : le clic n'attend jamais la fin du rapport.

6.2 Génération (asynchrone, Step Functions)

- **Explain** — réunit l'historique de la paire et les autres partenaires de la même période (DynamoDB), récupère jusqu'à trois pages Wikipédia pertinentes, puis demande à Claude Haiku 5.5, sur Amazon Bedrock, une explication structurée (causes possibles, vraisemblance, vérifications suggérées, sources citées).
- **BuildPdf** — construit le graphique d'évolution des prix FOB/CIF et met en page le rapport PDF, qu'elle écrit dans le bucket des rapports sous `reports/<reportId>.pdf`.
- Chaque appel à Bedrock est protégé par une nouvelle tentative avec attente croissante ; toute erreur non résolue fait échouer l'exécution avec une cause explicite, visible dans la console Step Functions et relançable depuis l'étape en échec.

6.3 Suivi et téléchargement

- L'interface sonde `GET /reports/{id}` toutes les 3 secondes (jusqu'à 5 minutes avant d'abandonner) et affiche « Génération en cours… ».
- Côté API, le statut est déduit sans table dédiée : si le PDF existe déjà dans S3, le statut est `generated` ; sinon, le statut de l'exécution Step Functions du même nom donne `in_progress` ou `failed`.
- Dès que le statut passe à `generated`, l'API renvoie une URL pré-signée (15 minutes) et l'interface affiche le lien « Télécharger le rapport PDF ».

7. Manuel d'utilisation

7.1 Connexion

L'application est accessible à l'adresse du domaine Amplify (ou `http://localhost:5173` en développement). La connexion se fait avec une adresse e-mail et un mot de passe créés par un administrateur ; il n'y a pas d'auto-inscription.

7.2 Lire le tableau de bord

- Choisir un **exportateur**, un **produit** (code HS à 4 chiffres) et une **fréquence** (mensuelle, trimestrielle, annuelle), puis cliquer sur « Afficher ».
- La heatmap affiche les dix partenaires les plus importants de l'exportateur pour ce produit, en lignes, et les périodes en colonnes.
- Légende des cellules : **vert** (cohérent), **rouge** (anomalie, cliquable), **rouge hachuré** (anomalie à sens unique : le flux n'est déclaré que par un pays, également cliquable), **gris** (aucune donnée).
- Survoler une cellule affiche son détail : prix FOB, prix CIF et écart.

7.3 Générer un rapport d'anomalie

- Cliquer sur une cellule rouge ouvre le panneau de rapport et démarre immédiatement la génération (voir section 6) ; aucune confirmation supplémentaire n'est nécessaire.
- Le panneau affiche la cause probable, les valeurs FOB/CIF et l'écart, puis le statut de la génération (« en cours… », avec une icône de chargement).
- Une fois le rapport prêt, un lien « Télécharger le rapport PDF » apparaît ; le PDF contient le résumé, les hypothèses de cause avec leur vraisemblance, des vérifications suggérées, une conclusion et la liste des sources (données Comtrade et pages Wikipédia citées).
- En cas d'échec, le panneau affiche la cause de l'erreur ; relancer la génération suffit en général (un nouveau clic sur la cellule).

7.4 Dépannage courant

Symptôme	Cause probable / action
Erreur 401 au chargement	Jeton expiré (1 heure) : se reconnecter.
« Aucune page Wikipédia n'a pu être consultée » dans le PDF	Wikipédia injoignable ou limite de débit atteinte : le rapport repose alors sur les seules données commerciales ; relancer plus tard pour obtenir les sources.
Génération bloquée sur « en cours… » plus de 5 minutes	Consulter l'exécution correspondante dans la console Step Functions (nom = identifiant du rapport affiché) ; elle peut être relancée depuis l'étape en échec.
Page blanche après déploiement du front-end	Variables d'environnement `VITE_*` absentes au moment du build Amplify : les renseigner puis redéployer.

8. Limites et pistes d'évolution

- **Durée du rechargement complet** — bornée par la limite Lambda de 15 minutes ; le rechargement actuel (2019 à aujourd'hui) prend de 5 à 10 minutes. Au-delà, la récupération devra être découpée par année (déjà supporté par la fonction d'ingestion).
- **Quota de l'API UN Comtrade** — 500 appels par jour ; un chargement complet en consomme 16, ce qui laisse une marge confortable pour des rechargements ponctuels.
- **Pas de modèle de repli** — un refus ou une erreur de Bedrock fait échouer l'étape d'explication sans bascule automatique vers un autre modèle ; l'identifiant du modèle reste toutefois un paramètre de déploiement, changeable sans modifier le code.
- **Contexte externe limité à Wikipédia** — source publique, sans clé ni inscription, mais qui ne couvre pas toujours l'actualité la plus récente d'un couple pays/produit.
- **Autorisation à un seul niveau** — tous les comptes ont les mêmes droits (lecture et génération) ; des groupes Cognito permettraient de distinguer consultation seule et déclenchement de rapports si ce besoin apparaissait.
- **Fiabilité du contenu généré** — le rapport propose des causes possibles, pas une conclusion certaine ; il est conçu comme un point de départ d'investigation, à vérifier avant toute décision, et le dit explicitement en pied de page.